

Extensión del Marco de *Community Membership Hiding* mediante Deep Reinforcement Learning

Alumno: Dante Culaciati **Co-Director:** Gabriel Tolosa **Director:** Esteban Feuerstein

Lugar de trabajo: Grupo Algoritmos, Instituto de Ciencias de la Computación,
Facultad de Ciencias Exactas y Naturales, Universidad de Buenos Aires

6 de Agosto 2025

Introducción

Los algoritmos de *community detection* permiten identificar *clusters* o comunidades en un grafo: grupos de nodos densamente conectados entre sí y comparativamente poco conectados con el resto de la red [1]. En plataformas de redes sociales, esta funcionalidad se emplea para descubrir grupos de usuarios con intereses afines, pero puede vulnerar deseos de privacidad y confidencialidad al revelar afiliaciones o patrones de comportamiento.

Para mitigar estos efectos surge el problema de *community membership hiding* (CMH): dado un grafo, un algoritmo de *community detection* $f(\cdot)$ y un nodo objetivo u , proponer una cantidad mínima de modificaciones estructurales (agregados o eliminaciones de aristas) de modo que u sea asignado a una comunidad distinta por $f(\cdot)$ [2]. El trabajo de Bernini, Silvestri y Tolomei [2] formula CMH como un objetivo contrafactual restringido y lo resuelve mediante *deep reinforcement learning* (Actor-Critic A2C), usando embeddings de nodos obtenidos con node2vec y una red de atención sobre grafos (GAT) para representar el estado del entorno.

Trabajos previos abordan problemas relacionados mediante algoritmos genéticos [3], heurísticas [4], métodos *greedy* [5], optimización por gradiente [6] y autoencoders de grafos [7]. A diferencia de estos, la formulación de Bernini, Silvestri y Tolomei [2] es flexible y extensible: el agente aprende una política que se puede transferir entre grafos y algoritmos de detección, tratando $f(\cdot)$ como **caja negra**. Nuestra investigación parte de esta base y busca extenderla en direcciones tanto arquitectónicas como conceptuales.

Objetivos

Habiendo replicado exitosamente los experimentos del paper base [2] y validado su comportamiento sobre los datasets originales (*words*, *kar*, *vote*, *pow*, *fb-75*), el objetivo principal de este proyecto es extender el marco de CMH en las siguientes direcciones concretas:

- **Mejoras arquitectónicas al agente.** Analizar el impacto de reemplazar la GAT original por GATv2 [8], e incorporar la identidad del nodo objetivo u como *feature* explícita del estado para evitar que el agente aprenda una política genérica de “mezclar comunidades”.
- **Extensión a múltiples nodos objetivo.** Inspirándonos en Fionda y Pirrò [9], extender CMH para ocultar simultáneamente a un subconjunto de nodos de la comunidad objetivo, redefiniendo la función de recompensa y analizando el escalado del presupuesto β .
- **Análisis de transferibilidad.** Diseñar experimentos con grafos sintéticos de estructura controlada (grafos k -regulares, Barabási-Albert, Erdős-Rényi) para caracterizar qué propiedades estructurales favorecen o dificultan la transferencia de la política aprendida.
- **Comunidades solapadas y variantes del espacio de acciones.** Explorar algoritmos de detección con solapamiento [10] y restricciones alternativas al espacio de acciones (*add-only*, *remove-only*, perturbación de atributos de nodos [11]).

Factibilidad

Esteban Feuerstein, director propuesto, es un reconocido investigador y profesor en Diseño y Análisis de Algoritmos, con especialización en grafos y redes sociales. El Dr. Gabriel Tolosa, propuesto como co-director, es profesor asociado e investigador en Ciencias de la Computación en la Universidad Nacional de Luján, con trayectoria en recuperación de información, redes sociales y ciencia de datos a gran escala.

La factibilidad técnica es sólida: el código del paper original (https://github.com/AndreaBe99/community_membership_hiding) ha sido replicado exitosamente, incluyendo correcciones de reproducibilidad (semillas fijas en `random`, `numpy` y `torch`) y optimizaciones al cómputo de baselines. Contamos con un entorno de experimentación funcional sobre los datasets originales y con resultados preliminares sobre las modificaciones arquitectónicas propuestas en el objetivo 1. Tenemos además contacto directo con los autores del paper base, quienes han

manifestado disposición a colaborar. Los datasets adicionales necesarios para los experimentos de transferibilidad (objetivo 3) son generables sintéticamente con bibliotecas estándar (**NetworkX**).

Plan de Trabajo

- T1. Revisión de la literatura y replicación del paper base.** Estudio de los trabajos relacionados en *community detection* [1, 12], *community hiding* [4, 9, 5] y reinforcement learning aplicado a grafos [13]. Replicación de los experimentos de Bernini, Silvestri y Tolomei [2] sobre los cinco datasets originales (*words*, *kar*, *vote*, *pow*, *fb-75*), corrección de problemas de reproducibilidad y validación de los resultados reportados.
- T2. Modificaciones arquitectónicas al agente.** Implementación de GATv2 [8] en reemplazo de la GAT original, e incorporación de la identidad del nodo objetivo u como *feature* explícita del estado. Evaluación comparativa de las cuatro configuraciones resultantes (arquitectura $\times$ feature) sobre todos los datasets y algoritmos de detección (*greedy*, *louvain*, *walktrap*), midiendo SR, NMI y F1.
- T3. Análisis de transferibilidad con grafos sintéticos.** Generación de grafos sintéticos con propiedades estructurales controladas (grafos k -regulares, modelos de Barabási-Albert y Erdős-Rényi) y evaluación del agente entrenado sobre *words* para caracterizar qué propiedades favorecen o dificultan la transferencia de la política aprendida.
- T4. Extensión a múltiples nodos objetivo.** Reformulación del problema CMH para un conjunto de nodos $U \subseteq V$, inspirada en Fionda y Pirrò [9]. Rediseño de la función de recompensa y del criterio de éxito, y análisis del comportamiento del agente en función del tamaño de U y del presupuesto de rewiring β .
- T5. Variantes del espacio de problema.** Adaptación del entorno para soportar comunidades solapadas [10], exploración de restricciones alternativas al espacio de acciones (*add-only*, *remove-only*) y perturbación de atributos de nodos [11].
- T6. Análisis comparativo y redacción del informe final.** Comparación sistemática de todas las variantes sobre un conjunto unificado de benchmarks, elaboración de conclusiones y redacción del informe de tesis.

Referencias

- [1] Santo Fortunato. «Community detection in graphs». En: *Physics Reports* 486.3–5 (feb. de 2010), págs. 75–174. ISSN: 0370-1573. DOI: [10.1016/j.physrep.2009.11.002](https://doi.org/10.1016/j.physrep.2009.11.002). URL: <http://dx.doi.org/10.1016/j.physrep.2009.11.002>.
- [2] Andrea Bernini, Fabrizio Silvestri y Gabriele Tolomei. «Evading Community Detection via Counterfactual Neighborhood Search». En: *Proceedings of the 30th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*. KDD '24. Barcelona, Spain: Association for Computing Machinery, 2024, págs. 131–140. ISBN: 9798400704901. DOI: [10.1145/3637528.3671896](https://doi.org/10.1145/3637528.3671896). URL: <https://doi.org/10.1145/3637528.3671896>.
- [3] Dong Liu et al. «Hiding ourselves from community detection through genetic algorithms». En: *Information Sciences* 614 (2022), págs. 123–137. ISSN: 0020-0255. DOI: <https://doi.org/10.1016/j.ins.2022.10.027>. URL: <https://www.sciencedirect.com/science/article/pii/S0020025522011471>.
- [4] Marcin Waniek et al. «Hiding individuals and communities in a social network». En: *Nature Human Behaviour* 2.2 (ene. de 2018), págs. 139–147. ISSN: 2397-3374. DOI: [10.1038/s41562-017-0290-3](https://doi.org/10.1038/s41562-017-0290-3). URL: <http://dx.doi.org/10.1038/s41562-017-0290-3>.
- [5] Shrivika Mittal, Debarka Sengupta y Tanmoy Chakraborty. «Hide and Seek: Outwitting Community Detection Algorithms». En: *IEEE Transactions on Computational Social Systems* 8.4 (2021), págs. 799–808. DOI: [10.1109/TCSS.2021.3062711](https://doi.org/10.1109/TCSS.2021.3062711).
- [6] Matteo Silvestri et al. *Community Membership Hiding via Gradient-based Optimization*. 2025. arXiv: [2502.00432 \[cs.SI\]](https://arxiv.org/abs/2502.00432). URL: <https://arxiv.org/abs/2502.00432>.
- [7] Dong Liu et al. «Community hiding using a graph autoencoder». En: *Knowledge-Based Systems* 253 (2022), pág. 109495. ISSN: 0950-7051. DOI: <https://doi.org/10.1016/j.knosys.2022.109495>. URL: <https://www.sciencedirect.com/science/article/pii/S0950705122007493>.
- [8] Shaked Brody, Uri Alon y Eran Yahav. *How Attentive are Graph Attention Networks?* 2022. arXiv: [2105.14491 \[cs.LG\]](https://arxiv.org/abs/2105.14491). URL: <https://arxiv.org/abs/2105.14491>.
- [9] Valeria Fionda y Giuseppe Pirrò. «Community Deception or: How to Stop Fearing Community Detection Algorithms». En: *IEEE Transactions on Knowledge and Data Engineering* 30.4 (2018), págs. 660–673. DOI: [10.1109/TKDE.2017.2776133](https://doi.org/10.1109/TKDE.2017.2776133).
- [10] Jierui Xie, Stephen Kelley y Boleslaw K. Szymanski. «Overlapping community detection in networks: The state-of-the-art and comparative study». En: *ACM Computing Surveys* 45.4 (ago. de 2013), págs. 1–35. ISSN: 1557-7341. DOI: [10.1145/2501654.2501657](https://doi.org/10.1145/2501654.2501657). URL: <http://dx.doi.org/10.1145/2501654.2501657>.
- [11] Jaewon Yang, Julian McAuley y Jure Leskovec. «Community Detection in Networks with Node Attributes». En: *2013 IEEE 13th International Conference on Data Mining*. IEEE, dic. de 2013. DOI: [10.1109/icdm.2013.167](https://doi.org/10.1109/icdm.2013.167). URL: <http://dx.doi.org/10.1109/ICDM.2013.167>.
- [12] Xing Su et al. «A Comprehensive Survey on Community Detection With Deep Learning». En: *IEEE Transactions on Neural Networks and Learning Systems* 35.4 (abr. de 2024), págs. 4682–4702. ISSN: 2162-2388. DOI: [10.1109/TNNLS.2021.3137396](https://doi.org/10.1109/TNNLS.2021.3137396). URL: <http://dx.doi.org/10.1109/TNNLS.2021.3137396>.
- [13] Ziheng Chen et al. «ReLAX: Reinforcement Learning Agent Explainer for Arbitrary Predictive Models». En: *Proceedings of the 31st ACM International Conference on Information and Knowledge Management*. CIKM '22. ACM, oct. de 2022, págs. 252–261. DOI: [10.1145/3511808.3557429](https://doi.org/10.1145/3511808.3557429). URL: <http://dx.doi.org/10.1145/3511808.3557429>.