



UNIVERSIDAD DE BUENOS AIRES
FACULTAD DE CIENCIAS EXACTAS Y NATURALES
DEPARTAMENTO DE COMPUTACIÓN

Mejorando el Ocultamiento de Membresía de Comunidades mediante Aprendizaje Profundo por Refuerzo

Tesis de Licenciatura en Ciencias de la Computación

Dante Culaciati

Director: Esteban Feuerstein

Codirector: [Nombre del Codirector]

Buenos Aires, 2026

MEJORANDO EL OCULTAMIENTO DE MEMBRRESÍA DE COMUNIDADES MEDIANTE APRENDIZAJE PROFUNDO POR REFUERZO

El problema de *Community Membership Hiding* (CMH), u *ocultamiento de membrresía de comunidades*, consiste en, dado un grafo, un algoritmo de detección de comunidades y un nodo objetivo u , encontrar un conjunto mínimo de reconexiones de aristas adyacentes a u de modo que el algoritmo deje de asignarlo a su comunidad original, mientras se preserva la integridad estructural del grafo. Este problema es relevante en el contexto de la privacidad en redes, donde los algoritmos de detección pueden revelar información sensible sobre los usuarios—como afiliaciones políticas o ideológicas—a partir de su posición estructural, sin que estos lo hayan divulgado explícitamente.

Trabajos recientes formularon CMH como un Proceso de Decisión de Markov (MDP) resuelto mediante Aprendizaje Profundo por Refuerzo (DRL), empleando una arquitectura Actor-Crítico (A2C). En este trabajo identificamos una limitación arquitectónica crítica de dicho método: el agente evalúa el grafo de forma global sin condicionar explícitamente en el nodo objetivo, lo que le impide aprender una política de ocultamiento específica.

Proponemos una arquitectura DRL novedosa que incorpora explícitamente la identidad del nodo objetivo como característica de entrada, utiliza *Graph Attention Networks v2* (GATv2) como codificador de grafos para aprovechar un mecanismo de atención dinámico y más expresivo, y combina señales estáticas y dinámicas que reflejan los cambios topológicos en tiempo real durante el proceso de reconexión. Extendemos el sistema de un único agente a una *Arquitectura Dual* que especializa agentes separados para la adición y la eliminación de aristas, e introducimos una heurística de *Subgrafado Guiado por Política* que hace el método escalable en grafos de gran tamaño.

La evaluación experimental sobre los benchmarks estándar del área demuestra que nuestra arquitectura supera consistentemente al agente DRL original y a los métodos basados en gradientes, logrando altas tasas de éxito con una perturbación estructural mínima.

Palabras clave: detección de comunidades, ocultamiento de membrresía de comunidades, aprendizaje por refuerzo profundo, redes de atención de grafos, privacidad en redes, GATv2, Actor-Crítico.

IMPROVING COMMUNITY MEMBERSHIP HIDING VIA DEEP REINFORCEMENT LEARNING

The *Community Membership Hiding* (CMH) problem asks: given a graph, a community detection algorithm, and a target node u , find a minimal set of edge rewirings adjacent to u such that the algorithm no longer assigns it to its original community, while preserving the overall structural integrity of the graph. This problem arises in the context of network privacy, where detection algorithms can inadvertently reveal sensitive affiliations—political or ideological—solely from a node’s structural position.

Recent work formulated CMH as a Markov Decision Process (MDP) solved via Deep Reinforcement Learning (DRL) using an Actor-Critic (A2C) architecture. In this thesis we identify a critical architectural limitation of that approach: the agent evaluates the graph globally without explicitly conditioning on the target node, thereby learning a generic community-shuffling policy rather than a targeted hiding strategy.

We propose a novel DRL architecture that explicitly incorporates the target node as an input feature, employs Graph Attention Networks v2 (GATv2) as the graph encoder to leverage a more expressive, dynamic attention mechanism, and combines static and real-time structural signals that track topological changes during rewiring. We extend the single-agent system to a Dual-Agent Architecture that specializes separate agents for edge addition and deletion, and introduce a Policy-Guided Subgraphing heuristic that makes the framework tractable on large graphs.

Extensive experimental evaluation on the standard benchmark datasets demonstrates that our architecture consistently outperforms both the original DRL agent and strong gradient-based baselines, achieving high hiding success rates with minimal structural perturbation.

Keywords: community detection, community membership hiding, deep reinforcement learning, graph attention networks, network privacy, GATv2, Actor-Critic.

AGRADECIMIENTOS

[Por completar.]

Índice general

1. Introducción	1
2. Marco Teórico	5
2.1 Grafos y Estructura de Comunidades	5
2.2 Algoritmos de Detección de Comunidades	5
2.3 Aprendizaje por Refuerzo	6
2.4 Redes Neuronales de Grafos	6
2.4.1 Graph Attention Networks (GAT)	7
2.4.2 GATv2: Atención Dinámica	7
2.5 El Algoritmo node2vec	7
3. Formulación del Problema	9
3.1 Definición Formal	9
3.2 Similitud de Grafo	10
3.3 Información Mutua Normalizada	10
3.4 Métricas de Evaluación	10
4. Trabajos Relacionados	11
4.1 El Agente CMH Original (Bernini et al., 2024)	11
4.2 The Right to Hide (Silvestri et al., 2025)	11
4.3 Problemas de Evasión en Grafos	11
5. Arquitectura Propuesta	13
5.1 Análisis del Agente Original	13
5.1.1 El Problema de Ceguera al Nodo Objetivo	13
5.1.2 Embeddings Estáticos de Nodos	13
5.1.3 Espacio de Acciones Indiferenciado	13
5.2 Construcción de Características Conscientes del Objetivo	14
5.3 Codificador de Grafo Basado en GATv2	14
5.4 Arquitectura Dual	15
5.5 Subgrafado Guiado por Política	15
5.6 Procedimiento de Entrenamiento	15
6. Evaluación Experimental	17
6.1 Configuración	17
6.2 Datasets	17
6.3 Baselines	17
6.4 Protocolo de Evaluación	18
6.5 Resultados	18
6.5.1 Comparación con el Agente Original	18
6.5.2 Comparación con los Métodos Basados en Gradientes	18
6.5.3 Ablación	18

7. Conclusiones y Trabajo Futuro	19
7.1 Resumen	19
7.2 Limitaciones	19
7.3 Trabajo Futuro	19
Apéndice	23
Detalles de Hiperparámetros	25
Descripción de los Datasets	27
Resultados Suplementarios	29

1. INTRODUCCIÓN

La ciencia moderna de redes ha traído avances significativos en nuestra comprensión de los sistemas complejos. Una de las propiedades estructurales más relevantes de los grafos que representan fenómenos del mundo real—desde plataformas de redes sociales hasta redes de interacción biológica—es su *estructura de comunidades*: la tendencia de los nodos a agruparse en conjuntos densamente conectados entre sí, con escasas conexiones hacia el resto de la red. Los algoritmos de detección de comunidades que descubren esta estructura han demostrado ser altamente efectivos [6], y son utilizados rutinariamente en plataformas a gran escala para caracterizar usuarios, personalizar contenidos y dirigir publicidad.

Sin embargo, esta funcionalidad conlleva un riesgo fundamental de privacidad. Cuando un grafo codifica relaciones sociales, la comunidad a la que pertenece un nodo puede revelar inadvertidamente afiliaciones sensibles—tendencias políticas, creencias religiosas, condiciones de salud o asociaciones ideológicas—a partir únicamente de su posición estructural, sin ninguna revelación explícita de dicha información. Esta preocupación no es meramente teórica: la detección de comunidades ha sido utilizada en la práctica para identificar grupos políticos en redes online [10] y para perfilar individuos en grafos sociales [5].

Para contrarrestar esto, el concepto de *Community Membership Hiding* (CMH) fue introducido por Bernini, Silvestri y Tolomei [1]. El objetivo del CMH es modificar estratégicamente la topología de una red—añadiendo o eliminando un número pequeño de aristas adyacentes a un nodo objetivo u —de modo que u deje de ser asignado a su comunidad original por un algoritmo de detección, mientras se mantiene mínima la perturbación del grafo. El algoritmo de detección se trata como una *caja negra*: el actor puede consultarlo pero no puede acceder a sus parámetros internos.

Bernini, Silvestri y Tolomei [1] formularon el CMH como un Proceso de Decisión de Markov (MDP) y lo resolvieron mediante Aprendizaje Profundo por Refuerzo (DRL) usando una arquitectura Actor-Crítico (A2C). Si bien ese trabajo demostró la viabilidad del paradigma DRL, exhibe una degradación notable del rendimiento en grafos de mayor tamaño, y—como demostramos en esta tesis—adolece de una limitación arquitectónica crítica: el agente evalúa la red de forma *global*, sin condicionar explícitamente en la identidad del nodo objetivo. Como consecuencia, el agente no puede aprender una política que dependa de quién es el objetivo; en cambio, aprende una estrategia genérica de reorganización de comunidades que desplaza al nodo objetivo de su comunidad como efecto secundario.

[Figura de marcador: Un grafo con tres comunidades (codificadas por color). El nodo objetivo u (marcado con una estrella) pertenece inicialmente a la comunidad azul. Tras la reconexión de aristas, u migra a la comunidad roja.]

Fig. 1.1: Un grafo con tres comunidades (codificadas por color). El nodo objetivo u (marcado con una estrella) pertenece inicialmente a la comunidad azul. Tras la reconexión de aristas, u migra a la comunidad roja.

Contribuciones

En esta tesis realizamos las siguientes contribuciones:

1. **Identificación de una limitación arquitectónica.** Demostramos formalmente que el agente DRL original produce salidas idénticas para distintos nodos objetivo dado el mismo estado del grafo, confirmando que no puede condicionar su política en el objetivo.
2. **Arquitectura consciente del nodo objetivo.** Proponemos una arquitectura DRL que incorpora explícitamente la identidad del nodo objetivo como característica de entrada. El codificador de grafo se reemplaza por *Graph Attention Networks v2* (GATv2) [3], que provee un mecanismo de atención más expresivo y condicionado al nodo consulta. Las características de los nodos combinan indicadores estáticos del grafo original con señales estructurales actualizadas dinámicamente durante el proceso de reconexión.
3. **Arquitectura Dual.** Extendemos el sistema de un único agente a una Arquitectura Dual que mantiene dos agentes especializados: uno para la adición de aristas y otro para su eliminación, cada uno con redes de política y valor propias entrenadas independientemente.
4. **Subgrafado Guiado por Política.** Para hacer el sistema escalable en grafos grandes, introducimos una heurística de Subgrafado Guiado por Política que restringe el codificador de grafo a un subgrafo relevante centrado en el nodo objetivo, reduciendo el costo computacional sin sacrificar la calidad de la política aprendida.
5. **Evaluación experimental extensiva.** Evaluamos todas las contribuciones propuestas sobre los datasets de benchmark estándar del área, comparando contra el agente DRL original y dos métodos basados en gradientes introducidos en Silvestri, Tolomei y Bernini [13].

Organización del trabajo

El resto de esta tesis se organiza de la siguiente manera. El Capítulo 2 presenta los conceptos necesarios sobre grafos, detección de comunidades, aprendizaje por refuerzo y redes neuronales de grafos. El Capítulo 3 formaliza el problema. El Capítulo 4 revisa los trabajos relacionados. El Capítulo 5 describe la arquitectura propuesta. El Capítulo 6 presenta la evaluación experimental. El Capítulo 7 concluye con una discusión y direcciones de trabajo futuro. Los Apéndices 7.3–7.3 contienen material suplementario.

2. MARCO TEÓRICO

Este capítulo introduce los conceptos fundamentales necesarios para comprender el resto de la tesis. Cubrimos los fundamentos de grafos y detección de comunidades, presentamos una definición formal del problema CMH, revisamos los elementos relevantes del Aprendizaje por Refuerzo, y describimos las redes de atención de grafos y el algoritmo node2vec.

2.1 Grafos y Estructura de Comunidades

Un *grafo* $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ consiste en un conjunto de nodos $\mathcal{V}$ y un conjunto de aristas $\mathcal{E} \subseteq \mathcal{V} \times \mathcal{V}$. Denotamos $|\mathcal{V}| = N$ y $|\mathcal{E}| = M$. En un grafo no dirigido, $(u, v) \in \mathcal{E}$ implica $(v, u) \in \mathcal{E}$. La mayoría de los datasets de este trabajo corresponden a grafos no dirigidos.

El *grado* de un nodo v , denotado $\deg(v)$, es el número de aristas incidentes en v . El grado medio del grafo es $\mu = 2M/N$. La *vecindad* de v es $\mathcal{N}(v) = \{w : (v, w) \in \mathcal{E}\}$.

Definición 2.1 (Estructura de comunidades). *Un grafo $\mathcal{G}$ exhibe estructura de comunidades si sus nodos pueden particionarse en grupos $\mathcal{C} = \{\mathcal{C}_1, \mathcal{C}_2, \dots, \mathcal{C}_k\}$ tal que la densidad de aristas dentro de cada grupo es significativamente mayor que la densidad de aristas entre grupos distintos.*

2.2 Algoritmos de Detección de Comunidades

Existe una gran variedad de algoritmos para la detección de comunidades en la literatura [6]. En esta tesis nos centramos en tres métodos ampliamente utilizados, todos tratados como *cajas negras* por nuestro agente.

Optimización greedy de modularidad. Clauset, Newman y Moore [4] introdujeron un algoritmo voraz que maximiza la *modularidad*, definida como la fracción de aristas internas a las comunidades menos la fracción esperada bajo un modelo nulo con la misma secuencia de grados:

$$Q = \frac{1}{2M} \sum_{i,j} \left[A_{ij} - \frac{k_i k_j}{2M} \right] \delta(c_i, c_j),$$

donde A es la matriz de adyacencia, k_i es el grado del nodo i , y $\delta(c_i, c_j)$ vale 1 si i y j pertenecen a la misma comunidad y 0 en caso contrario. El algoritmo parte de cada nodo en su propia comunidad y fusiona iterativamente pares de comunidades que producen el mayor aumento de Q .

Algoritmo de Louvain. Blondel et al. [2] propusieron una heurística de dos fases para la maximización de la modularidad. En la primera fase, cada nodo se mueve a la comunidad del vecino que produce la mayor ganancia de modularidad. En la segunda fase, las comunidades se colapsan en super-nodos y la primera fase se repite sobre el grafo resultante. El proceso continúa hasta que no sea posible ninguna mejora adicional.

Algoritmo de Walktrap. Pons y Latapy [12] introdujeron un algoritmo basado en caminatas aleatorias. La intuición es que las caminatas aleatorias cortas tienden a permanecer dentro de la misma comunidad; por lo tanto, los nodos visitados por el mismo conjunto de caminatas cortas probablemente pertenecen a la misma comunidad. El algoritmo define una distancia entre nodos basada en las probabilidades de transición de una caminata aleatoria de t pasos y utiliza clustering jerárquico para identificar comunidades.

2.3 Aprendizaje por Refuerzo

El *Aprendizaje por Refuerzo* (AR) es un paradigma del aprendizaje automático en el cual un *agente* aprende a tomar decisiones secuenciales interactuando con un *entorno* con el objetivo de maximizar una señal acumulada de *recompensa*. La interacción procede en pasos de tiempo discretos: en cada paso t , el agente observa un estado $s_t \in \mathcal{S}$, selecciona una acción $a_t \in \mathcal{A}(s_t)$ según una política π , y recibe una recompensa escalar r_t transitando al estado s_{t+1} .

Proceso de Decisión de Markov. La formalización estándar es el Proceso de Decisión de Markov (MDP), definido por la tupla $(\mathcal{S}, \mathcal{A}, P, R, \gamma)$, donde $\gamma \in [0, 1]$ es el factor de descuento. El retorno desde el paso t es:

$$G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1}.$$

El objetivo es encontrar una política π^* que maximice el retorno esperado:

$$\pi^* = \arg \max_{\pi} \mathbb{E}_{\pi} [G_t \mid s_t = s].$$

Métodos Actor-Crítico. Los métodos de gradiente de política optimizan una política paramétrica $\pi_{\theta}(a \mid s)$ siguiendo el gradiente del retorno esperado. Las arquitecturas Actor-Crítico mantienen dos redes: el *actor*, que representa la política π_{θ} , y el *crítico*, que estima la función de valor de estado $V_{\phi}(s)$ para calcular la *ventaja*:

$$A_t = R_t - V_{\phi}(s_t).$$

Entrenar el crítico para proveer una base precisa reduce sustancialmente la varianza del estimador del gradiente de política sin introducir sesgo, lo que lleva a un aprendizaje más estable.

El algoritmo *Advantage Actor-Critic* (A2C) [9], que constituye la base del agente CMH original y de nuestra arquitectura propuesta, actualiza sincronamente el actor y el crítico utilizando la ventaja estimada a partir de trayectorias recolectadas.

2.4 Redes Neuronales de Grafos

Las Redes Neuronales de Grafos (GNNs) son una familia de modelos de aprendizaje profundo diseñados para operar sobre datos estructurados en grafos. La idea central es el *paso de mensajes*: cada nodo agrega información de sus vecinos, transformando los mensajes agregados mediante parámetros aprendibles para producir una nueva representación. Formalmente, la capa l de una GNN actualiza la representación del nodo v como:

$$\mathbf{h}_v^{(l)} = \text{ACTUALIZAR}^{(l)}\left(\mathbf{h}_v^{(l-1)}, \text{AGREGAR}^{(l)}\left(\left\{\mathbf{h}_u^{(l-1)} : u \in \mathcal{N}(v)\right\}\right)\right).$$

2.4.1 Graph Attention Networks (GAT)

Las Graph Attention Networks [15] reemplazan la agregación uniforme o basada en grado de las GNNs estándar por un mecanismo de atención aprendible:

$$\alpha_{vu} = \frac{\exp(\text{LeakyReLU}(\mathbf{a}^\top [\mathbf{W}\mathbf{h}_v \parallel \mathbf{W}\mathbf{h}_u]))}{\sum_{w \in \mathcal{N}(v)} \exp(\text{LeakyReLU}(\mathbf{a}^\top [\mathbf{W}\mathbf{h}_v \parallel \mathbf{W}\mathbf{h}_w]))}.$$

2.4.2 GATv2: Atención Dinámica

Brody, Alon y Yahav [3] identificaron una limitación fundamental de la GAT original: su atención es *estática*, lo que significa que el ranking de los vecinos es el mismo para todos los nodos consulta. GATv2 corrige esto reordenando las operaciones:

$$e(\mathbf{h}_v, \mathbf{h}_u) = \mathbf{a}^\top \text{LeakyReLU}(\mathbf{W}_1 \mathbf{h}_v + \mathbf{W}_2 \mathbf{h}_u),$$

lo que hace que la función de puntuación sea un MLP de 2 capas sobre las características concatenadas. La atención resultante es *dinámica*: el ranking de los vecinos puede diferir para cada nodo consulta, haciendo de GATv2 un modelo estrictamente más expresivo. Esta propiedad es particularmente deseable en nuestro contexto, donde la importancia de cada vecino para el nodo objetivo debe depender de las propias características del objetivo.

2.5 El Algoritmo node2vec

En muchos grafos del mundo real, los nodos no tienen vectores de características naturales. node2vec [7] aborda esto aprendiendo un embedding de dimensión d para cada nodo mediante un procedimiento análogo a word2vec. El algoritmo genera secuencias de nodos realizando *caminitas aleatorias sesgadas de segundo orden* sobre el grafo, y luego entrena un modelo skip-gram con negative sampling sobre dichas secuencias.

El sesgo se controla mediante dos parámetros: p (probabilidad de retorno al nodo anterior) y q (probabilidad de explorar nodos lejanos). Ajustando p y q , node2vec puede capturar *homofilia* (nodos de la misma comunidad se embeben cerca) o *equivalencia estructural* (nodos con roles estructurales similares se embeben cerca).

En la arquitectura CMH original, node2vec se usa para generar características iniciales de los nodos. Sin embargo, estos embeddings se calculan una única vez sobre el grafo original y no se actualizan a medida que el grafo cambia durante el proceso de reconexión. Esta es una de las limitaciones que abordamos en nuestra propuesta.

3. FORMULACIÓN DEL PROBLEMA

En este capítulo damos una definición formal del problema de Community Membership Hiding. La Sección 3.1 introduce la condición de engaño, el presupuesto de modificaciones y el espacio de acciones admisibles. Las Secciones 3.2 y 3.3 definen las medidas de similitud a nivel de grafo y de comunidad utilizadas a lo largo del trabajo. La Sección 3.4 presenta las métricas de evaluación (SR, NMI, F1).

3.1 Definición Formal

Sea $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ un grafo no dirigido y no ponderado, y sea f un algoritmo de detección de comunidades que, dado $\mathcal{G}$, produce una partición $\mathcal{C} = f(\mathcal{G}) = \{\mathcal{C}_1, \mathcal{C}_2, \dots, \mathcal{C}_k\}$ de $\mathcal{V}$ en k comunidades no solapadas.

Dado un nodo objetivo $u \in \mathcal{V}$ con comunidad original $\mathcal{C}_i = f_u(\mathcal{G})$, el objetivo del CMH es encontrar un grafo modificado $\mathcal{G}' = (\mathcal{V}, \mathcal{E}')$ tal que se satisfaga la siguiente *condición de engaño*:

Definición 3.1 (Condición de engaño). *Sea $\mathcal{C}'_i = f_u(\mathcal{G}')$ la comunidad asignada a u en $\mathcal{G}'$. La condición de engaño es:*

$$\text{sim}(\mathcal{C}_i \setminus \{u\}, \mathcal{C}'_i \setminus \{u\}) \leq \tau,$$

donde sim es una función de similitud entre comunidades y $\tau \in [0, 1]$ es el umbral de engaño. Un valor de $\tau = 0$ requiere que $\mathcal{C}_i$ y $\mathcal{C}'_i$ sean completamente disjuntas (engaño duro), mientras que $\tau = 1$ permite que sean idénticas (trivialmente satisfecho).

Siguiendo Bernini, Silvestri y Tolomei [1], utilizamos el *Coficiente de Sørensen-Dice* (DSC) como sim :

$$\text{DSC}(A, B) = \frac{2|A \cap B|}{|A| + |B|}.$$

El DSC vale 0 cuando las comunidades son disjuntas y 1 cuando son idénticas.

Definición 3.2 (Restricción de presupuesto). *El número de modificaciones de aristas está acotado por un presupuesto $\beta = \lfloor \beta_{\text{mul}} \cdot \mu \rfloor$, donde $\mu = 2M/N$ es el grado medio y $\beta_{\text{mul}} \in \{1/2, 1, 2\}$ es un multiplicador.*

Definición 3.3 (Acciones admisibles). *El espacio de acciones está restringido de la siguiente manera. Sea $\mathcal{C}_i = f_u(\mathcal{G})$ la comunidad actual de u :*

- **Eliminación de arista:** *el agente puede eliminar una arista (u, v) solo si $v \in \mathcal{C}_i$ (vecino intra-comunitario de u).*
- **Adición de arista:** *el agente puede añadir una arista (u, v) solo si $v \notin \mathcal{C}_i$ (candidato inter-comunitario).*

3.2 Similitud de Grafo

Además de la condición de engaño a nivel de comunidad, medimos la distorsión estructural global introducida por la reconexión mediante la *similitud de Jaccard* sobre los conjuntos de aristas:

$$\text{JAC}(\mathcal{G}, \mathcal{G}') = \frac{|\mathcal{E} \cap \mathcal{E}'|}{|\mathcal{E} \cup \mathcal{E}'|}.$$

3.3 Información Mutua Normalizada

Para cuantificar el impacto de la reconexión sobre la *estructura de comunidades* en su conjunto, utilizamos la Información Mutua Normalizada (NMI) [14] entre la partición original $\mathcal{C} = f(\mathcal{G})$ y la modificada $\mathcal{C}' = f(\mathcal{G}')$:

$$\text{NMI}(\mathcal{C}, \mathcal{C}') = \frac{2I(\mathcal{C}; \mathcal{C}')}{H(\mathcal{C}) + H(\mathcal{C}')}.$$

Un NMI alto tras el ocultamiento indica que la estructura global de comunidades ha sido bien preservada.

3.4 Métricas de Evaluación

Evaluamos los métodos con tres métricas:

Tasa de Éxito (SR). La fracción de instancias de prueba en las que la condición de engaño (Definición 3.1) se satisface.

NMI. El NMI promedio entre $f(\mathcal{G})$ y $f(\mathcal{G}')$ sobre todas las instancias de prueba. Un NMI mayor indica menor distorsión estructural.

Score F1. La media armónica de SR y NMI:

$$F_1 = \frac{2 \cdot \text{SR} \cdot \text{NMI}}{\text{SR} + \text{NMI}}.$$

4. TRABAJOS RELACIONADOS

Este capítulo revisa los trabajos más directamente relacionados con nuestras contribuciones. La Sección 4.1 describe el agente CMH basado en DRL de Bernini, Silvestri y Tolomei [1], que constituye nuestra referencia principal. La Sección 4.2 presenta los métodos basados en gradientes de Silvestri, Tolomei y Bernini [13], que forman un segundo conjunto de baselines fuertes. La Sección 4.3 sitúa nuestro trabajo en el contexto más amplio de los problemas de evasión en grafos.

4.1 El Agente CMH Original (Bernini et al., 2024)

Bernini, Silvestri y Tolomei [1] fueron los primeros en formular el CMH como un MDP y resolverlo con DRL. Su arquitectura—que constituye nuestra referencia principal—consta de:

1. Un **codificador de grafo** basado en una GNN que produce una representación del estado del grafo. Las características de los nodos son vectores aleatorios o embeddings de node2vec calculados sobre el grafo original.
2. Una **red Actor-Crítico** (A2C) que, dado el grafo codificado, produce una distribución de probabilidad sobre los nodos candidatos para el próximo paso de reconexión y un estimador escalar de valor.

El agente se entrena sobre el dataset **words** usando el algoritmo de detección **greedy**, y se evalúa su transferibilidad a otros datasets y algoritmos.

4.2 The Right to Hide (Silvestri et al., 2025)

Silvestri, Tolomei y Bernini [13] abordaron el CMH desde un ángulo diferente, formulándolo como un problema de optimización continua. Definen una relajación diferenciable de la pérdida de engaño y aplican descenso por gradiente proyectado, obteniendo dos variantes: ∇ -CMH y ∇ -CMH (proyectado). Estos métodos basados en gradientes son computacionalmente eficientes y logran tasas de ocultamiento competitivas con una huella estructural bien controlada. Utilizamos ambos como baselines fuertes en nuestra evaluación.

4.3 Problemas de Evasión en Grafos

El CMH es parte de una familia más amplia de *problemas de evasión en grafos*, en los que se busca una modificación estructural para engañar a un algoritmo que opera sobre el grafo. Problemas relacionados incluyen ataques adversariales sobre clasificación de nodos [8], evasión de predicción de enlaces, y ejemplos adversariales a nivel de clasificación de grafos. Nuestro trabajo se centra específicamente en la variante de detección de comunidades y no asume ningún conocimiento de los parámetros internos del algoritmo de detección.

5. ARQUITECTURA PROPUESTA

En este capítulo analizamos primero el agente DRL original e identificamos sus limitaciones principales (Sección 5.1). Luego describimos paso a paso las mejoras propuestas: características conscientes del nodo objetivo (Sección 5.2), el codificador de grafo basado en GATv2 (Sección 5.3), la Arquitectura Dual (Sección 5.4), y el Subgrafado Guiado por Política (Sección 5.5). La Sección 5.6 describe el procedimiento de entrenamiento y la estructura de recompensas.

5.1 Análisis del Agente Original

5.1.1 El Problema de Ceguera al Nodo Objetivo

Una observación central que motiva este trabajo es la siguiente. En la arquitectura original [1], el codificador de grafo recibe el estado completo $\mathcal{G}_t$ como entrada y produce una representación vectorial para cada nodo. La red del actor produce luego una distribución de probabilidad sobre todos los nodos candidatos, y el entorno aplica la acción seleccionada *en relación al nodo objetivo u* (por ejemplo, elimina la arista entre u y el vecino intra-comunitario seleccionado).

El problema crítico es que en ningún punto de este flujo se comunica la identidad de u a la red. El codificador y el actor no reciben ninguna señal sobre *quién* es el objetivo.

Para verificar esto, fijamos todas las semillas aleatorias y ejecutamos el agente original sobre el mismo grafo con distintos nodos objetivo. Las probabilidades de salida del actor y el estimador de valor del crítico fueron idénticos para todos los objetivos en el primer paso de cada episodio, confirmando que el modelo es completamente ajeno a u .

Como consecuencia, el agente no puede adaptar su política a la posición estructural específica del nodo objetivo. En cambio, aprende una estrategia global de reconexión que tiende a aumentar la mezcla de comunidades en general—reorganizando efectivamente la estructura de comunidades del grafo completo. Si bien esto puede desplazar accidentalmente a u de su comunidad, no es ni eficiente ni confiable, especialmente cuando el presupuesto β es pequeño.

5.1.2 Embeddings Estáticos de Nodos

La arquitectura original usa embeddings de node2vec calculados *una única vez* sobre el grafo original $\mathcal{G}$ y reutilizados a lo largo de todo el episodio. A medida que el proceso de reconexión modifica el grafo, los embeddings se vuelven progresivamente obsoletos y no reflejan la topología actual. Además, calcular node2vec requiere un paso de preprocesamiento separado y es computacionalmente costoso para grafos grandes.

5.1.3 Espacio de Acciones Indiferenciado

El agente original maneja tanto la adición como la eliminación de aristas con la misma red de política, sin distinguir entre los dos tipos de acciones. Sostenemos que estas dos tareas tienen una estructura fundamentalmente distinta: eliminar aristas intra-comunitarias requiere identificar qué vecinos contribuyen más a la pertenencia de u a su comunidad,

mientras que agregar aristas inter-comunitarias requiere identificar qué nodos externos serían más útiles para atraer a u hacia una comunidad diferente. Combinar ambas tareas puede limitar la expresividad de la política aprendida.

5.2 Construcción de Características Conscientes del Objetivo

Nuestra primera modificación aborda el problema de ceguera al nodo objetivo. Para cada nodo $v \in \mathcal{V}$, construimos un vector de características $\mathbf{x}_v \in \mathbb{R}^d$ que incorpora explícitamente si v es el nodo objetivo:

$$\mathbf{x}_v = \left[f_{\text{struct}}(v) \mid \mathbf{1}[v = u] \right],$$

donde $f_{\text{struct}}(v)$ es un vector de características estructurales y $\mathbf{1}[v = u]$ es un indicador binario que vale 1 solo para el nodo objetivo u .

Las características estructurales $f_{\text{struct}}(v)$ combinan:

- **Características estáticas** calculadas sobre el grafo original $\mathcal{G}_0$ (grado, coeficiente de clustering, centralidad de intermediación, etiqueta de comunidad) y mantenidas fijas durante todo el episodio.
- **Características dinámicas** recalculadas en cada paso sobre el grafo actual $\mathcal{G}_t$ (grado actual, etiqueta de comunidad actual, número actual de vecinos intra- e inter-comunitarios), que reflejan el efecto de las acciones de reconexión previas.

Al incluir $\mathbf{1}[v = u]$ en el vector de características, el codificador GATv2 puede calcular pesos de atención que dependan explícitamente de si un nodo es el objetivo. Esto permite al modelo dar tratamiento especial a la vecindad de u y agregar información relevante para el objetivo de ocultamiento.

5.3 Codificador de Grafo Basado en GATv2

Reemplazamos el codificador GNN original por una red GATv2 multi-capa [3]. Como se discutió en la Sección 2.4, GATv2 provee atención dinámica: la importancia relativa de cada vecino puede diferir para cada nodo consulta, lo cual es esencial cuando el nodo objetivo u necesita focalizarse en un subconjunto específico de sus vecinos.

El codificador GATv2 toma como entrada el grafo actual $\mathcal{G}_t$ con características de nodos $\mathbf{X}_t \in \mathbb{R}^{N \times d}$ y produce una matriz de embeddings $\mathbf{H} \in \mathbb{R}^{N \times d'}$. Las redes del actor y del crítico operan sobre estos embeddings.

Actor. El actor puntúa cada nodo candidato v en el conjunto de acciones $\mathcal{A}(s_t)$:

$$\text{puntuacin}(v) = \text{MLP}_{\text{actor}}([\mathbf{h}_u \parallel \mathbf{h}_v]),$$

donde $\mathbf{h}_u$ y $\mathbf{h}_v$ son los embeddings del nodo objetivo y del candidato v respectivamente. Esta formulación garantiza que la puntuación de cada candidato esté condicionada en el embedding del nodo objetivo.

Crítico. El crítico estima el valor del estado:

$$V(s_t) = \text{MLP}_{\text{critico}}(\text{READOUT}(\mathbf{H})),$$

donde READOUT es una operación de pooling sobre todos los embeddings de nodos.

5.4 Arquitectura Dual

La Arquitectura Dual mantiene dos sistemas Actor-Crítico independientes:

- Agente_{add}: maneja las acciones de *adición* de aristas (seleccionando candidatos inter-comunitarios para conectar con u).
- Agente_{del}: maneja las acciones de *eliminación* de aristas (seleccionando vecinos intra-comunitarios de u cuya arista se elimina).

En cada paso, el entorno determina si la siguiente acción debe ser una adición o una eliminación (en función de la disponibilidad y el presupuesto actual), y despacha al agente correspondiente. Cada agente tiene su propio codificador GATv2, red del actor y red del crítico, con parámetros entrenados independientemente.

La justificación es que la adición y la eliminación de aristas son tareas estructuralmente distintas. El agente de eliminación necesita identificar qué conexiones intra-comunitarias anclan más fuertemente a u en su comunidad; el agente de adición necesita identificar qué nodos externos atraerían más efectivamente a u hacia una comunidad diferente. Separar estas tareas en redes especializadas permite que cada agente desarrolle representaciones adaptadas a su subtarea.

5.5 Subgrafado Guiado por Política

En grafos grandes con miles o decenas de miles de nodos, no es eficiente que una GNN procese el grafo completo en cada paso de cada episodio. El Subgrafado Guiado por Política aborda esto restringiendo el codificador a un subgrafo $\hat{\mathcal{G}}_t$ centrado en el nodo objetivo:

$$\hat{\mathcal{G}}_t = \mathcal{G}_t \left[\bigcup_{k=0}^K \mathcal{N}^k(u) \right],$$

donde $\mathcal{N}^k(u)$ denota el conjunto de nodos alcanzables desde u en a lo sumo k saltos en $\mathcal{G}_t$. En nuestros experimentos, $K = 2$ (el subgrafo ego de 2 saltos de u) proporciona un buen equilibrio entre riqueza representacional y tractabilidad computacional.

5.6 Procedimiento de Entrenamiento

Entrenamos el agente sobre el dataset **words** usando el algoritmo de detección **greedy**, siguiendo la misma configuración que el trabajo original. El método de cambio de comunidad 1 (selección aleatoria de comunidad) se usa durante el entrenamiento para exponer al agente a tipos diversos de nodos y estructuras de comunidades.

Utilizamos la actualización A2C con el optimizador Adam y una tasa de aprendizaje de 7×10^{-4} . La recompensa en cada paso combina un término de progreso (cuánto ha mejorado la condición de engaño) y una penalización que desincentiva la perturbación estructural excesiva.

6. EVALUACIÓN EXPERIMENTAL

Este capítulo evalúa todas las contribuciones propuestas frente a los baselines descritos en el Capítulo 4. La Sección 6.1 describe el entorno experimental. La Sección 6.2 introduce los datasets de benchmark y la Sección 6.3 define los baselines. La Sección 6.4 especifica el protocolo de evaluación. La Sección 6.5 reporta los resultados, organizados en: comparación con el agente original, comparación con los métodos basados en gradientes, estudio de ablación y evaluación en el escenario asimétrico.

6.1 Configuración

Todos los experimentos se ejecutaron en una instancia AWS EC2 `g4dn.xlarge` (4 vCPUs a 2.5 GHz, 16 GiB RAM, GPU NVIDIA T4) con Ubuntu 24.04 y la AMI Deep Learning Base OSS Nvidia Driver. El algoritmo de entrenamiento es A2C con el optimizador Adam. Entrenamos por 10.000 episodios sobre `words` y reportamos resultados promediados sobre 100 ejecuciones de prueba por configuración, con semillas aleatorias fijas para reproducibilidad.

6.2 Datasets

Utilizamos los cinco datasets del benchmark CMH estándar:

Tab. 6.1: Estadísticas de los datasets.

Dataset	Nodos	Aristas	Grado medio
<code>words</code>	—	—	—
<code>kar</code>	—	—	—
<code>vote</code>	—	—	—
<code>pow</code>	—	—	—
<code>fb-75</code>	—	—	—

El dataset `words` se usa exclusivamente para entrenamiento. Los cuatro restantes se usan para evaluación.

6.3 Baselines

Comparamos contra los siguientes métodos de referencia:

1. **Aleatorio**: selecciona un nodo aleatorio del conjunto de acciones admisibles.
2. **Basado en grado**: selecciona el nodo admisible de mayor grado.
3. **Basado en intermediación**: selecciona el nodo admisible de mayor centralidad de intermediación.
4. **Roam**: heurística que reduce la centralidad del nodo objetivo dentro de su comunidad.

5. **Greedy**: heurística relajada que selecciona vorazmente el paso de reconexión más prometedor según el grado de los nodos.
6. **Agente DRL original** [1].
7. **∇ -CMH y ∇ -CMH (proyectado)** [13].

6.4 Protocolo de Evaluación

Evaluamos cada método sobre todas las combinaciones de $\tau \in \{0,3,0,5,0,8\}$ y $\beta_{\text{mul}} \in \{0,5,1,2\}$. Para cada combinación y dataset, ejecutamos 100 episodios de prueba. Evaluamos tanto el escenario *simétrico* (el mismo algoritmo de detección usado en entrenamiento, **greedy**) como el *asimétrico* (con **louvain** y **walktrap**), que evalúa la transferibilidad de la política aprendida.

6.5 Resultados

[Resultados a ser finalizados. Los experimentos preliminares confirman la tendencia esperada: la arquitectura propuesta supera consistentemente al agente DRL original en SR, NMI y F1 sobre todos los datasets y configuraciones. Las tablas y figuras finales se incluirán al completar la ejecución experimental completa.]

6.5.1 Comparación con el Agente Original

6.5.2 Comparación con los Métodos Basados en Gradientes

6.5.3 Ablación

Para aislar la contribución de cada componente, realizamos un estudio de ablación comparando:

1. **Original**: el agente DRL de Bernini, Silvestri y Tolomei [1].
2. + **Feature de objetivo**: arquitectura original con indicador del nodo objetivo añadido.
3. + **GATv2**: arquitectura consciente del objetivo con codificador GATv2.
4. + **Agentes duales**: arquitectura completa propuesta con especialización de agentes duales.

7. CONCLUSIONES Y TRABAJO FUTURO

Este capítulo cierra la tesis. La Sección 7.1 resume las contribuciones y los principales resultados experimentales. La Sección 7.2 discute las limitaciones del trabajo actual, y la Sección 7.3 esboza las direcciones más prometedoras para investigación futura.

7.1 Resumen

En esta tesis estudiamos el problema de Community Membership Hiding e identificamos una limitación crítica en el enfoque DRL del estado del arte: el agente original no conoce la identidad del nodo objetivo, aprendiendo una política genérica de reorganización de comunidades en lugar de una estrategia de ocultamiento dirigida. Propusimos una arquitectura novedosa que aborda esta limitación incorporando el nodo objetivo como característica explícita de entrada, reemplazando el codificador GNN por GATv2 para aprovechar atención dinámica condicionada por consulta, combinando señales estáticas y dinámicas, introduciendo una Arquitectura Dual para políticas especializadas de adición y eliminación de aristas, y desarrollando una heurística de Subgrafado Guiado por Política para escalabilidad.

Los resultados experimentales muestran que cada uno de estos componentes contribuye positivamente al rendimiento general, y la arquitectura completa supera consistentemente a los métodos existentes en todos los datasets, algoritmos de detección y configuraciones de parámetros.

7.2 Limitaciones

Varias limitaciones persisten en nuestro trabajo actual:

- El método asume conocimiento completo del grafo. En la práctica, un usuario puede tener acceso solo a una vista local de la red.
- Solo se consideran comunidades no solapadas. Muchas redes del mundo real exhiben estructura de comunidades solapadas.
- El algoritmo de detección se trata como caja negra. Conocer el algoritmo (escenario white-box) podría permitir estrategias más dirigidas y eficientes.

7.3 Trabajo Futuro

Comunidades solapadas. Extender la formulación del problema y la arquitectura para manejar comunidades solapadas ampliaría significativamente la aplicabilidad del método.

Conocimiento parcial del grafo. Un escenario más realista asume que el ocultador tiene acceso solo a una ego-red local o a un subgrafo muestreado.

Ocultamiento white-box. Si el algoritmo de detección de comunidades es conocido, se podría explotar su estructura para diseñar estrategias de ocultamiento más eficientes.

Múltiples nodos objetivo. Una extensión al ocultamiento simultáneo de múltiples nodos, posiblemente coordinado mediante Aprendizaje por Refuerzo Multi-Agente, es un paso natural.

Datasets sintéticos. Probar la arquitectura sobre grafos sintéticos con estructura de comunidades conocida (por ejemplo, modelos de bloque estocástico) proveería estudios de ablación controlados e intuiciones teóricas sobre cuándo y por qué el método tiene éxito.

BIBLIOGRAFÍA

- [1] Andrea Bernini, Fabrizio Silvestri y Gabriele Tolomei. “Evading Community Detection via Counterfactual Neighborhood Search”. En: *Proceedings of the ACM Web Conference 2024 (WWW '24)*. arXiv:2306.16:10. 2024.
- [2] Vincent D. Blondel et al. “Fast unfolding of communities in large networks”. En: *Journal of Statistical Mechanics: Theory and Experiment* 2008.10 (2008), P10008.
- [3] Shaked Brody, Uri Alon y Eran Yahav. “How Attentive are Graph Attention Networks?” En: *International Conference on Learning Representations (ICLR)* (2022).
- [4] Aaron Clauset, M. E. J. Newman y Cristopher Moore. “Finding community structure in very large networks”. En: *Physical Review E* 70.6 (2004), pág. 066111.
- [5] Michael Fire, Roy Goldschmidt y Yuval Elovici. “Online Social Networks: Threats and Solutions”. En: *IEEE Communications Surveys & Tutorials* 16.4 (2014), págs. 2019-2036.
- [6] Santo Fortunato. “Community detection in graphs”. En: *Physics Reports* 486.3–5 (2010), págs. 75-174.
- [7] Aditya Grover y Jure Leskovec. “node2vec: Scalable Feature Learning for Networks”. En: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2016.
- [8] Thomas N. Kipf y Max Welling. “Semi-Supervised Classification with Graph Convolutional Networks”. En: *International Conference on Learning Representations (ICLR)*. 2017.
- [9] Volodymyr Mnih et al. “Asynchronous Methods for Deep Reinforcement Learning”. En: *Proceedings of the 33rd International Conference on Machine Learning* (2016).
- [10] Arvind Narayanan y Vitaly Shmatikov. “De-anonymizing Social Networks”. En: *IEEE Symposium on Security and Privacy* (2009), págs. 173-187.
- [11] M. E. J. Newman. *Networks: An Introduction*. Oxford University Press, 2010.
- [12] Pascal Pons y Matthieu Latapy. “Computing communities in large networks using random walks”. En: *Journal of Graph Algorithms and Applications* 10.2 (2006), págs. 191-218.
- [13] Fabrizio Silvestri, Gabriele Tolomei y Andrea Bernini. *The Right to Hide: Masking Community Membership*. 2025. arXiv: 2501.05120 [cs.SI].
- [14] Alexander Strehl y Joydeep Ghosh. “Cluster Ensembles — A Knowledge Reuse Framework for Combining Multiple Partitions”. En: *Journal of Machine Learning Research* 3 (2003), págs. 583-617.
- [15] Petar Veličković et al. “Graph Attention Networks”. En: *International Conference on Learning Representations (ICLR)*. 2018.

Apéndice

. DETALLES DE HIPERPARÁMETROS

Este apéndice lista el conjunto completo de hiperparámetros utilizados en los experimentos. Todos los valores fueron seleccionados mediante búsqueda en grilla sobre la partición de validación de `words`, salvo indicación contraria.

Tab. .1: Hiperparámetros de la arquitectura propuesta.

Hiperparámetro	Valor
Tasa de aprendizaje (Adam)	7×10^{-4}
Factor de descuento γ	—
Coeficiente de entropía c_e	—
Coeficiente de valor c_v	—
Capas de GATv2	—
Dimensión oculta de GATv2	—
Cabezas de atención	—
Dimensión oculta del actor	—
Dimensión oculta del crítico	—
Episodios de entrenamiento	10.000
Saltos del subgrafo K	2
Compromiso de recompensa α	—

. DESCRIPCIÓN DE LOS DATASETS

Este apéndice provee información adicional sobre los cinco datasets de benchmark utilizados en la evaluación.

words. Red de co-ocurrencia de palabras extraída de un corpus de texto. Los nodos representan palabras y las aristas conectan palabras que co-ocurren en la misma oración. Este dataset se usa exclusivamente para entrenamiento.

kar (*Club de Karate*). La red del Club de Karate de Zachary [11], un benchmark clásico para la detección de comunidades. Contiene 34 nodos que representan miembros de un club de karate universitario, con aristas correspondientes a interacciones sociales fuera del club.

vote. Red de votación política donde los nodos representan legisladores y las aristas representan registros de votación alineados.

pow (*Red Eléctrica*). Red de alta tensión donde los nodos son generadores, transformadores y subestaciones, y las aristas son líneas de suministro eléctrico. Esta red tiene una estructura fundamentalmente distinta a las redes sociales, proveyendo una prueba heterogénea de generalización.

fb-75. Un subgrafo del dataset de redes ego de Facebook, seleccionado por su mayor tamaño relativo a los otros benchmarks. Este dataset es el principal banco de pruebas para la evaluación de escalabilidad del Subgrafado Guiado por Política.

. RESULTADOS SUPLEMENTARIOS

Este apéndice contiene tablas de resultados completas para todas las combinaciones de τ , β_{mul} , dataset y algoritmo de detección, complementando los resultados resumidos presentados en el Capítulo 6.

[Tablas a agregar al completar la ejecución experimental completa.]

[Figura de marcador: Resultados completos de SR en todos los datasets, valores de τ , multiplicadores de presupuesto y algoritmos de detección (escenarios simétrico y asimétrico).]

Fig. .1: Resultados completos de SR en todos los datasets, valores de τ , multiplicadores de presupuesto y algoritmos de detección (escenarios simétrico y asimétrico).

[Figura de marcador: Resultados completos de NMI en todos los datasets, valores de τ , multiplicadores de presupuesto y algoritmos de detección.]

Fig. .2: Resultados completos de NMI en todos los datasets, valores de τ , multiplicadores de presupuesto y algoritmos de detección.